第一章

第一节：数据载入及初步观察（以泰坦尼克数据为例）

- 数据的载入方式

  `pandas.read_filename(file)`，例如`pandas.read_csv（'train.csv'）`和`pandas.read_table('train.csv')`。

  当然，这只是最基础的载入方式，在涉及到文件编码和分割等问题时还需要用到其他的参数。涉及到路径时需要注意相对路径和绝对路径，其中从文件中复制的路径往往是以''\"分割的，而python读文件的路径则以'/'分割，在使用'\"时需要在路径前加上‘r'才能正常读入文件。

  其中，pandas.read_csv()是从csv文件读入数据，pandas.read_table()则是从文本文件中读入数据。前者是后者的包装，将后者中的分割符置为','便可得到相同的结果，这其实也与csv文件的编码方式有关，如果将csv文件用文本方式打开，你会发现它是一个以逗号为分隔符的文本列表。如下图所示。

```
PassengerId,Survived,Pclass,Name,Sex,Age,SibSp,Parch,Ticket,Fare,Cabin,Embarked
1,0,3,"Braund, Mr. Owen Harris",male,22,1,0,A/5 21171,7.25,,S
2,1,1,"Cumings, Mrs. John Bradley (Florence Briggs Thayer)",female,38,1,0,PC 17599,71.2833,C85,
3,1,3,"Heikkinen, Miss. Laina",female,26,0,0,STON/O2. 3101282,7.925,,S
4,1,1,"Futrelle, Mrs. Jacques Heath (Lily May Peel)",female,35,1,0,113803,53.1,C123,S
5,0,3,"Allen, Mr. William Henry",male,35,0,0,373450,8.05,,S
6,0,3,"Moran, Mr. James",male,,0,0,330877,8.4583,,Q
7,0,1,"McCarthy, Mr. Timothy J",male,54,0,0,17463,51.8625,E46,S
8,0,3,"Palsson, Master. Gosta Leonard",male,2,3,1,349909,21.075,,S
9,1,3,"Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)",female,27,0,2,347742,11.1333,,S
```

  另外，如果遇到量级特别大的数据，直接将数据全部读入则显得不是那么明智了，此时我们可以使用`chunksize`参数将数据分块导入，“分而治之”：

```
#写入代码
chunk=pd.read_csv('train.csv',chunksize=500)
print(type(chunk))
bench=chunk.get_chunk(5)
print(bench)
```

```
<class 'pandas.io.parsers.TextFileReader'>
   PassengerId  Survived  Pclass  \
0            1         0       3
1            2         1       1
2            3         1       3
3            4         1       1
4            5         0       3

                                                Name     Sex  Age  SibSp  \
0                            Braund, Mr. Owen Harris    male   22      1
1  Cumings, Mrs. John Bradley (Florence Briggs Th...  female   38      1
2                             Heikkinen, Miss. Laina  female   26      0
3       Futrelle, Mrs. Jacques Heath (Lily May Peel)  female   35      1
4                           Allen, Mr. William Henry    male   35      0

   Parch            Ticket     Fare Cabin Embarked
0      0         A/5 21171   7.2500   NaN        S
1      0          PC 17599  71.2833   C85        C
2      0  STON/O2. 3101282   7.9250   NaN        S
3      0            113803  53.1000  C123        S
4      0            373450   8.0500   NaN        S
```

分块读出数据之后，使用`chunk.get_chunk()`将数据取出转换为df类型。

-

- 数据的初步探索
  数据的探索方式有许多，比如说查看数据的行数和列数、数据的特征名称、标签名等，pandas也为我们提供了许多的接口供使用。下面将简要介绍几个探索数据的函数。
  `df.head()`：查看DataFrame的部分数据，默认显示前5行，可以改变函数的参数调整显示的行数。
  `df.info()`:查看数据的基本信息，包括行数、列数、df的数据类型等。
  `df.tail()`:其用法与df.head()类似，不过df.tail()是查看数据的末尾数据，默认也是5行。
  `df.isnull()`：返回df中是否为空的布尔值，一般可以结合`.sum()`等函数一起使用。
  `df.colunms`:返回df列名。

- 数据保存
  一般而言，我们对数据处理完之后需要将处理好的数据进行保存（提交测试集），pandas也提供了保存数据的函数，`df.to_filename()`，比如说`df.to_csv()`，第一个参数为保存文件的名称，需要注意的是，如果保存的文件中有着特殊的字符（比如说中文）则可能需要调整文件的编码以免出现乱码问题，事实上，在读取文件时也需要注意文件的编码格式。

第二节：pandas基础

- DataFrame和Series
  Dataframe与Series均是pandas中的基础数据类型，按照我的个人理解，DataFrame是一个张量，而Series则是向量，二者的维度有所区别，通俗点将，DataFrame大一些，它的组成元素是Series。两个函数均可以字典作为参数，将字典转化为pandas的数据结构。

- 查看列的值
  在第一节的笔记中我写到了`df.columns`对象可用于查看数据的所有列名称，这里不过多赘述；下面记录查看某一列的方法：
  `df['列名']`取出该列的所有元素，返回Series类型的数据，可使用切片的方式取出想要数目的数据。
  `df['列名'].unique()`不重复的查看列中元素，找出所出现值的集合。

- 删除多余的列
  在教程中，实例的代码为`del test_1['a']`，在后文中提到了`df.drop()`函数，由此可以想到，`df.drop()`函数也可以用于删除列（记得将inplace=True），不过在使用该函数时需要对列进行操作，将axis置1，

- pandas中的布尔运算
  为了更好地理解教程中的代码，不妨先将教程中的代码拆开看：

```
data["Age"]<10
```

```
0      False
1      False
2      False
3      False
4      False
       ...
886    False
887    False
888    False
889    False
890    False
Name: Age, Length: 891, dtype: bool
```

，发现`data['Age']<10`返回了Age列的布尔值，如此，`data[data["Age"]<10]`的含义就很明显了：从data中取出Age<10 的数据。任务

二的代码含义也于此类似。
值得注意的是，取出的数据的索引仍是原来数据的索引，如需重新改变索引值，可以使用`df.reset_index()`函数

- 取出特定的行列
`df.iloc[参数1,参数2];df.loc[参数1,参数2]`：其中iloc支持字符取数据，loc支持用索引取数据，参数1取特定行，参数二取特定列。

第三节：探索性数据分析

- 对df进行排序
`df.sort_index(axis=0,ascending=True)`按照索引进行排序，默认按照行索引升序排序，axis=1按照列索引排序，ascending=False时按降序排
`df.sort_value(by='',ascending=True)`按照列的值进行排序，'by'的参数即所选择的列，默认升序排。

- 数据相加
在pandas中可以使用"+"将2个df中的数据进行相加，返回一个新的df，对应的行和列会变成相加后的结果，没有对应的行和列会成为nan

- 查看数据基本信息
`describe()`函数，查看数据的均值、均差和四分位数等，DataFrame和Series均有这个函数。

第二章

第一节：数据清洗及特征处理

查看缺失值：

- df.info:返回df的行列信息，可以通过查看每列值的总数判断是否有缺失值。
- Series.isnull():返回一个bool型的array，如果是空值则会在相应的索引出置True，否则为False，可以与.sum()连用查看缺失值的数目。（True在运算时为1，False为0.）

处理缺失值：

- 最简单的方法：`pd.fillna()`，使用括号里的参数填充缺失值。
- 使用sklearn：`sklearn.preprocessing.SimpleImpute`处理，不过sklearn处理缺失值相比pandas较麻烦，所以不常用。

另外，在处理缺失值时，可以使用预测算法进行缺失值填充，将缺失数量最多的特征作为标签，特征中未缺失的作为train，有缺失值的作为test，将原来的标签加入特征中训练填充缺失值。（具体的案例可以看菜菜的机器学习课堂中用随机森林处理缺失值）

处理重复值：

- sklearn处理：`sklearn.feature_select.VarianceThreshold:VarianceThreshold（）`可以用于删除方差小于threshold的特征，默认threshold为0，所以可以用来删除重复值。
- df.drop_duplicates()：实际上df.duplicate返回的是个bool型的张量，df.drop_duplicates()则是丢掉了其中值为True的部分。

对文本类型进行转换（字符型数据编码）：

- 使用`sklearn.preprocessing.OrdinalEncoder`：对数据进行编码，默认从0开始，可将编码后的数字都+1运算得到从1开始的编码，返回np.array数组。使用.categories_查看特征名。
- `sklearn.preprocessing.OneHotEncoder`：独热编码，记得用toarray函数将数值取出，使用.get_feature_names()查看特征名。

分箱

- `pd.cut（x,bins,right=True,labels=None,include_lowest=False）`:按照所传参数进行分箱，默认等位分5箱，当传入的列表时按照列表划分区间分箱（默认前开后闭），可通过将include_lowest置True调成闭区间。
- `Sklearn.preprocessing.KBinsDcretizer`：待处理数据必须大于一维（pd.cut,pd.qcut只能处理一维）大的
  ，有'Ordinal''Onehot'的方式给箱子编码，但是KBinsDcretizer在处理一维数据时无法像pd.cut()一样能够按照指定区间或者指定百分数区间划分，它只能在等宽（strategy='uniform'，相中极差相等）等位（strategy='quantile',箱中特征数目相等）和聚类（strategy=‘kmeans’）中选择分箱方法。

第二~三节：数据重构

- pd.concact()：数据拼接，axis=0上下拼接，axis=1左右拼接
- df.append():在df的下方加入数组。
- `pd.merge(left, right, how``=``'inner'``, on``=``None``, left_on``=``None``, right_on``=``None``,``left_index``=``False``, right_index``=``False``, sort``=``True``,``suffixes``=``(``'_x'``,<span> </span>``'_y'``), copy``=``True``, indicator``=``False``, ``validate``=``None``)`:默认按照所有相同的列中的相同元素拼接（取按相同列中的行相同值左右拼接），当需要指定某些列时将指定的列传给on，how后面的参数表示取并集（outer）、交集（inner）、保留右边所有（right，左边缺失项赋Nan）、保留左边所有（right，右边缺失项为Nan）
- `df.join(other, on=None, how='left', lsuffix=' ', rsuffix=' ', sort=False)`：作用与merge类似（按行索引左右拼接），但是merge会去掉重复的列，而join保留。

- 分组操作：`df.groupby()`：按照所传入的字段分组，将一个DataFrame分成许多子DataFrame

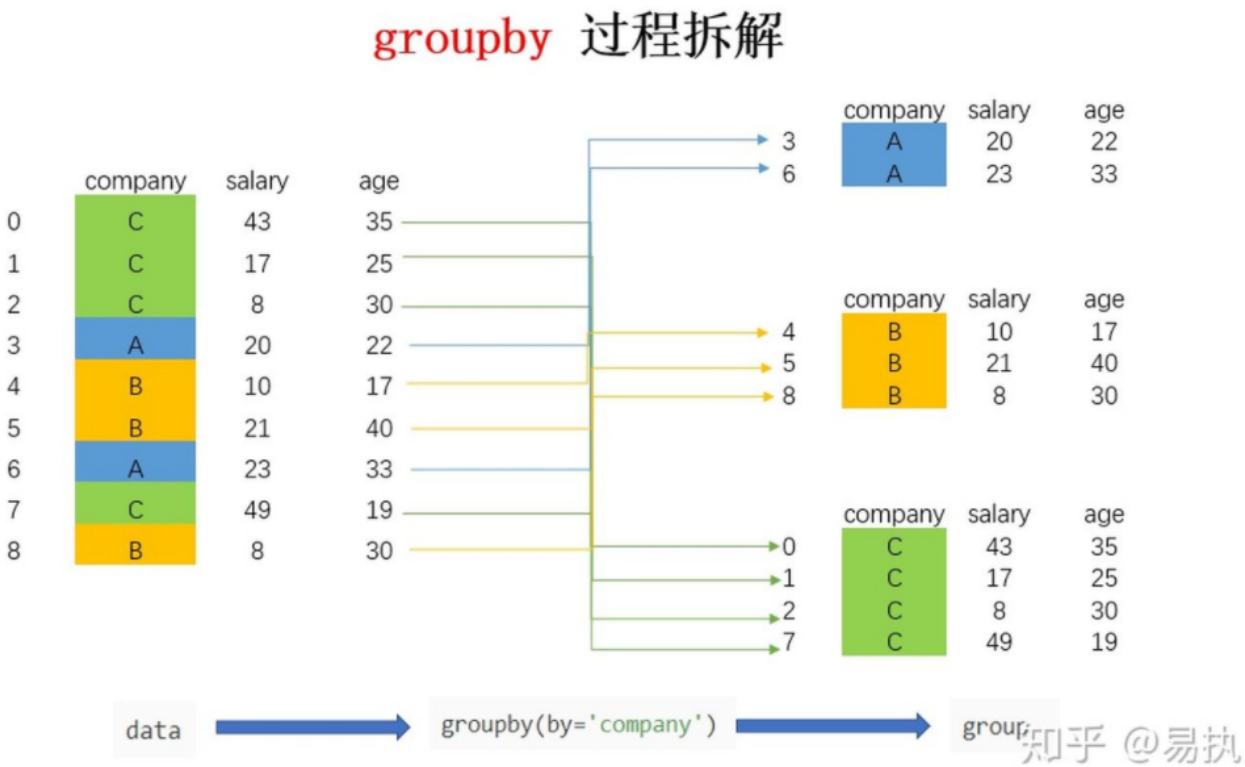

在分组操作之后常常使用`.agg()`和`.transform()`聚合操作，得出每一组元素的最值、求和、计数等，需要对不同特征采用不同操作时，可向函数中传入字典，例如：`data.groupby("Sex").agg({"Survived":"sum","Fare":"mean"})`这样则会返回如图所示的一个结果

Sex	Survived	Fare
female	233	44.479818
male	109	25.523893